

数据驱动放宽临床试验入组标准：这项工作做了什么

三页解读·第二轮大修版（中心结论已再次改变）

一、一句话

Trial Pathfinder (Liu 等, Nature 2021) 用 Shapley 值找出「限制了人数却没带来疗效」的入组标准并放宽, 宣称由此既能多纳入病人、又能得到更好的疗效估计。我们把这两个承诺分开做了样本外检验, 四轮审稿之后的结论是: **多纳入病人这一条主要由规则的构造决定**——把规则放到「所有 512 个子集」里去比, 在相同入组人数下它是否还有优势, **这两个队列的规模判不出来**: 点估计在 colon 是 63.4%、Rotterdam 是 57.1%, 但把不确定性做到病人层面之后, 区间都包含 0.5。它落在「人数—风险比」经验前沿上的比例只有 3.0% 和 1.0%; 不过这个前沿本身是从同一批留出数据里挑最优挑出来的, 带乐观偏倚, 我们另外量化了这个偏倚有多大。至于疗效估计要多少数据才够: 在我们模拟的这些机制里, **单靠队列人数、事件数或有效样本量都定不出一个通用的门槛**, 而且我们也**说不出决定它的是哪个量**(第六轮审稿指出 16 个情景只能说明机制间有异质性, 不能证明这种要求「不存在」, 标题已改)——第三轮我们曾说是「最强的那条稀释性标准」, 这一条已经撤回。这是一个否定性结论, 也是我们认为最有用的一条。

二、原文做了什么, 我们问了什么

Trial Pathfinder 把每条入组标准看成合作博弈的参与者, 用 Shapley 值分摊各自对疗效估计的边际贡献, 值为负的保留、其余放宽; 在一个肺癌真实世界数据库上它同时放大了合格人群、降低了风险比。

我们注意到三件事: 已有评价都是样本内的; 「更多病人」和「更好估计」被当成一对报告, 但没有理由认为两者需要同样多的数据、甚至是同一类命题; 风险比不可折叠, 缩小人群本身就会让它移动。

三、怎么做的

样本外 按治疗组和事件分层随机对半分, 只在一半上选标准, 再把方案拿到另一半上评分, 重复 400–500 次。

全子集对照 既然规则保留的是标准的子集, 「比完整方案纳入更多」不可能有别的结果。所以把全部 512 个子集都在留出的那一半上评分, 在**相同入组人数**下比较, 并看规则离可达前沿有多远。

嵌套自助 重复划分用的是同一批病人, 跨划分标准误低估了总体不确定性。外层对队列自助抽样(按病人 ID 划分, 避免泄漏), 把算法稳定性和总体不确定性分开。

因子设计模拟 评分集固定 10 万人、真值已知, 只让拟合集变化; 再用分辨率 IV 部分因子设计在六个因子上各取两水平共 16 个情景, 报告**固定样本量下的成功概率**。

两个公开队列做基准: colon (辅助结肠癌随机试验, $n = 619$, 完整方案保留 176 人 / 56 事件) 和 Rotterdam (乳腺癌登记队列, $n = 2982$, 保留 419 人 / 191 事件)。事件数比人数小得多, 也更要紧。

四、五个发现

1. 「多纳入病人」主要是构造性的; 规则很少落在经验前沿上, 但这个前沿本身是乐观的

500 次划分里, 合格人数的最小差值恰好是 0, 从不为负——这正是子集关系决定的。文献一直在报的那个 0.978 「承诺兑现率」, 衡量的是规则移除起约束作用的标准的频率, 而不是移除得对不对。

公平的对照是把**全部 512 个子集**都在留出的那一半上评分(第一轮用「随机去掉同样条数」不公平, 因为两者纳入的人数差很多)。在合格人数相差 10% 以内的子集中, 规则的风险比更低的比例是 63.4% (colon) 和 57.1% (Rotterdam), 病人层面的区间分别是 $[0.40, 0.86]$ 和 $[0.39, 0.75]$; 在 RMST 上是 41.1% 和 59.0%。**所有这些区间都包含 0.5**——既证不出优势也证不出没有优势。这是我们第三轮之后最重要的一处措辞改动。

前沿分析: 如果存在另一个子集, 纳入人数不少于规则、风险比不高于规则, 就说规则被支配了。规则**落在前沿上的比例只有 3.0% 和 1.0%**, 中位有 117 和 85 个子集支配它。

但审稿人第三轮指出: 这个前沿是**在同一批留出数据上从 512 个带噪声的估计里挑最优挑出来的**, 带「胜者诅咒」式的乐观偏倚。真值已知的模拟给出量级: 表面支配者里只有 19.5% 在总体上真的支配, 37.6% 能在另一半独立数据上重现。第四轮我们又在真实队列里做了**三分法**。第五轮审稿要求把三个量分开: (a) 挑选那一份上的支配者, 是乐观的经验量; (b) **把这些预先选定的子集拿到没用过的那一份上重新评价, 这是唯一的确定量**——colon 只有 35.3% 仍然支配, 规则未被任何预选子集支配的比例是 21.0% (Rotterdam 12.0%), 病人层面区间 $[0.04, 0.36]$ 和 $[0.04, 0.36]$, 而同一个三分设计下挑选份上的经验口径只有 2.5% / 2.7% (第六轮审稿要求和同一设计比, 不能跟对半划分比, 后者同时改变了评价集大小); (c) 在检验那一份上重新扫描全部 512 个子集, 仍然是经验最优, 只作描述。方向不变(大多数划分里规则仍被支配), 但只报 (a) 会把差距夸大。所以现在的说法是: 规则离**这个带乐观偏倚的经验最优**有相当距离; 它离真正的最优方案有多远, 这两个队列答不了。

2. 疗效估计这条承诺: 观察到的比例偏低, 但这既不能说明没守住, 也不能说明守住了

样本外对比	colon (n=619)	Rotterdam (n=2982)
终点；截断时间；划分次数	time, status; 1825 天; 500	dtime, death; 2555 天; 400
多纳入人数	+61	+226
风险比之差; P(更低)	+0.067; 0.290	+0.005; 0.522
RMST 之差; P(更大)	-1.4 天; 0.508	+5.4 天; 0.580
P(更低) 的 95% 区间	[0.04, 0.69]	[0.15, 0.88]

最后一行来自嵌套自助（150 次外层重抽 × 25 次内层划分），也是全文唯一的区间口径：外层自助分布的 95% 百分位区间。第二轮审稿指出原实现有泄漏——自助样本里同一病人的副本可能落到划分两侧；改成按病人 ID 划分后区间反而变窄。总标准差 0.194 中，内层蒙特卡洛成分 0.084、外层抽样成分 0.174。

区间几乎覆盖了整个取值范围：colon 这个队列分不清「十次里有九次守住」和「一次都守不住」。0.290 和 0.522 是这两个数据集的性质，不是对方法成功率的估计；用它们下「承诺没守住」的判断是过头的，第四轮审稿在这点上是对的，全文已改。

3. 关键不是队列多大——但关键到底是什么，我们说不出来

第一轮我们说：16 个情景里 9 个在 18000 人以内达不到阈值，删失几乎全落在「效应修饰是否集中」这个因子上。审稿人指出两个问题。一是只用「能观察到阈值」的 6 个情景算离散度，是有选择偏倚的；改用**固定样本量下的成功概率**（16 个情景全都有值，不存在删失）后，我们原来说的「事件数、有效样本量比人数更不稳」**不成立**——按三种口径分箱，组内离散度分别是 0.34、0.35、0.34，无法区分。这条建议已撤回。

二是「集中 vs 分散」这个对比本身可能是机械的：我们把每条标准的系数直接除以份数，分散那一臂的**稀释系数**也跟着从 0.32 掉到 0.128，而稀释正是规则必须检出的东西（只有放宽一条「选进了获益更少的人」的标准，风险比才会降）。审稿人是对的。

我们另做一组模拟把两者拆开：总效应修饰固定为 0.85，只改分布方式。稀释系数固定 0.30 时，在 600/2000/6000/18000 人处的成功概率，富集集中在一条是 0.26 / 0.37 / 0.58 / 0.85，摊到两条是 0.23 / 0.43 / 0.79 / 0.87，摊到四条是 0.17 / 0.39 / 0.78 / 0.95；把总量不变的稀释劈成两半后变成 0.07 / 0.11 / 0.19 / 0.43。

第三轮和第四轮又推翻了我们从这组数字里读出的两条结论。一是我们说「把富集摊薄没关系」，**加上蒙特卡洛区间之后它其实是有帮助的**：在 6000 人处提高了 0.21，区间 [0.08, 0.34]。二是我们说「决定数据量的是最强稀释系数的大小」，**这一条也撤回**：把稀释系数减半的同时，可达的改进幅度也差不多减半了（0.0203 → 0.0098），系数和「奖品」在这个设计里是绑在一起的，谁的功劳分不开。现在只保留更弱的说法：数据量要求取决于稀释信号相对于噪声的强度，而这个强度正是分析本身要估计的东西，所以无条件的门槛给不出来——和功效计算要先假定效应量是同一种处境。正文表 2 现已标注为**敏感性分析**，不再当作可以读出样本量要求的设计曲线。我们试过的最有希望的候选量是「标准特异的信噪比」（最强稀释标准的总体 Shapley 值除以它在该拟合规模下估计的标准差）：在 12 个模拟格子上它对成功率的排序（Spearman 0.86）好于单纯的样本量（0.45）。但 12 个格子不足以确立一个决定性的量，而且信噪比本身就随样本量上升、两者在设计上相关，所以只作为方向报告。

所以真正决定数据需求的是**最强那条稀释性标准的系数大小**。而这恰恰是分析本身要估计的量——正性/重叠、逻辑蕴含、交互杠杆都能事前算，唯独它不能。因此无论用人数、事件数还是有效样本量，都给不出一个事前数据需求。这就是本文的中心结论，它是否定性的。

4. 低于阈值时，选出的方案会比原方案略差

用「后悔值」来衡量。先把它定义清楚：这是在对数风险比这一个目标上，所选方案与「使风险比最低的那个子集」之间的差距，不考虑人数、安全性或任何别的临床目标；不同方案对应不同目标人群，所以「后悔值更大」意思是离最低风险比更远，不等于对病人更差。完整方案自己的后悔值是 0.0544。规则在 300 个拟合病人时的后悔值是 0.0727，**比完整方案还大**；约 1000 人处打平；到 20000 人降到 0.0078。也就是说，对这个规模的队列，在这一个目标上，预期结果不是「改进幅度较小」，而是**得到一个略微更偏离最优的方案**，并且把更多病人纳入其中。这是关于一个生成模型、一个单目标的陈述，不是说该方案在临床上更差。

5. 混杂调整不充分时，方法看起来更成功，实际选得更差

三条臂共享同一个结局模型，所以真实因果效应在三条臂里完全一样，变的只是治疗分配和能调整什么。正确调整混杂后，5167 人处的成功概率从随机化的 0.937 降到 0.808——大约需要两倍样本。但从倾向性模型里漏掉一个混杂因子，概率回到 0.936，看上去和随机化一样好。真相是：被检测的那个量本身被偏倚放大了（0.0310 → 0.0408，大 32%），而**正确选中标准集的概率同时从 0.280 掉到 0.116**。看起来一样可靠，但正确选中率下降了一半以上。

推论：在真实世界数据上看到方法「表现良好」，不是调整充分的证据。可用的敏感性分析是比较不同丰富程度的调整集、看差距是否随调整变充分而缩小——但这只在新增变量确实是混杂因子时成立；加进工具变量会放大偏倚，加进对撞因子会制造偏倚。它是一个值得留意的警报，不是一个能定案的检验。

五、四轮审稿指出的错误

错误一、二 原稿说 Shapley 效率公理在风险比尺度上只近似成立，**不成立**：穷举枚举下任何尺度都精确成立（验证到 $2.2e-16$ 和 $8.3e-17$ ）。同一稿把「多纳入病人」当成经过验证的收益，其实是构造性的（见发现 1）；两处均已全文改写。

漏查 Rotterdam 在完整方案内存在**正性假设问题**：419 人里 132 个倾向值顶在截断边界，加权有效样本量只有名义的 37%；化疗几乎只给了年轻绝经前女性。该队列现在全部按描述性报告，因果解读只靠随机化队列和模拟。

错误三、四 第二轮：嵌套自助有泄漏——自助样本里同一病人的副本可能落到划分两侧；已按病人 ID 划分并加断言，重算后区间变窄。同一轮里，只用「能观察到阈值」的 6 个情景算离散度有选择偏倚，据此得出的结论**不成立**，已撤回。

错误五 第二轮：非可折叠性一节写「被选中的低风险人群有更多绝对生存空间可赚」，**方向反了**——RMST 差 $0.664 \rightarrow 0.599$ 、 $0.425 \rightarrow 0.322$ ，低风险人群绝对获益更少。

错误六 第三轮：我们写「把富集摊薄没关系」，其实在 6000 人处是有帮助的（+0.21，区间 [0.08, 0.34]）；第七轮自查发现改后的「摊薄从不吃亏」同样过头——只有 6000 人这一档区间不含零，600 人那档点估计还是反向的，现已按档说明。同节「稀释系数是决定性的量」也撤回：系数和可达改进幅度在设计上绑定。

错误七（最严重） 第四轮：正文和补充材料对同一个量给出不同的数，我们上一轮把它解释成蒙特卡洛噪声。真正的原因要糟得多——第二、三轮新增的**11 个脚本把 Rotterdam 的终点写成了「无复发生存时间 + 死亡指示」在 1825 天截断**，而表 1 用的是正确的「死亡时间 + 死亡指示」在 2555 天截断。时间和事件指示不配对，会系统性缩短事件时间。这不是两次运行的差异，是两个不同的终点。已全部改正并重算。

错误八 第七轮，也是最锋利的一条统计意见：三分法那几个量的**区间和点估计并不是同一个统计量**——外层自助每抽一次只做 25 次内层划分，点估计却用 400/500 次，区间因此混进了内层蒙特卡洛方差、偏宽。我们注意到了症状（两次运行最多差 0.14）却没顺着它得出结论。新增的表 S1e 把长运行切成互不重叠的小块，给出**独立的 R 次划分估计的实测离散度和均值**，而不是只给 $s/\sqrt{R}$ 这个恒等式；表 S3、S3c 对每个量同时给出原始区间和压掉内层方差后的区间，并报告端点自身的蒙特卡洛误差。口径也改了：这些区间**近似、覆盖率未经验证**，confirmatory（确证）一词已全部撤下。

错误九 第七轮自查：三种「信息货币」（人数/事件数/有效样本量）差值报的是**自助均值**而非观察值。每次重抽都会重切四分位边界，两者不但不等、符号还相反。现改报观察值，自助只给区间。

结构性补救 现在所有真实队列的点估计都由**一个脚本 analysis/primary.R 一次算出**并写进同一个结果文件，摘要、正文、表 1、补充材料全部从它读数，没有一处手抄；嵌套自助只负责不确定性。导出时有三条断言（终点配对、截断时间、两套估计的一致性），违反即中止构建。

六、三个能被单独拿走用的副产品

交互杠杆 闭式量 $L = 1 - p(ij)/p(i) - p(ij)/p(j) + p(ij)$ ，只用入组率、不用结局数据。原稿把「杠杆低」说成「结构上测不出」**不够准确**：它是按已知因子的衰减，信号仍取决于效应大小和样本量；真正测不出的只有逻辑蕴含。

蕴含检测器 若标准 i 逻辑上蕴含 j，这对的交互是算术恒等式，无论样本量多大都无信息，必须从检验族里剔除。

双估计量并行 同时报告风险比和 RMST 差。条件风险比固定为 0.6 的模拟里，一条没改变任何人相对获益的标准，其对数风险比 Shapley 值却随预后异质性从 -0.0008 长到 -0.066；异质性为零时假象消失。

七、这篇文章的定位

它不是在说 Trial Pathfinder 错了。原文的做法在它自己的数据规模上有其道理，我们复制出来的规则在总体层面确实收敛到最优标准集。我们做的是：把两个被捆绑报告的承诺拆开，指出一个是构造性的、另一个的成立与否**这个规模的公开队列判不出来**；说明数据量要求为什么不能无条件地给；并提供三个动手前就能算的诊断量。

八、可能会被问到的三个问题

既然规则在入组上不优于随机放宽，那它的价值在哪里？

因为入组人数通常不是唯一目的。规则换来的可能是估计质量，代价是比它能做到的少招一些人。但在**相同入组人数**下它是否仍有这个优势，这两个队列的规模判不出来（区间都包含 0.5）。这个取舍只跟完整方案比是显现不出来的。

实际操作上我该怎么做？

第四步。（1）先把出于安全性、耐受性、给药可行性的标准标记为**不可放宽**。（2）看结局之前先算交互杠杆和逻辑蕴含。

（3）检查完整方案内部的正性/重叠。（4）判断有没有一条标准集中了足够差异获益；没有的话，只报告人群扩大，不报告疗效改善。