

这篇文章讲了什么

三页内容提要 · 只讲文章的主张与证据，不讲修改历程

一、一句话

Trial Pathfinder (Liu 等, Nature 2021) 用 Shapley 值挑出「限制了人数、却没给疗效估计带来好处」的入组标准并放宽, 宣称由此**同时**得到更多病人和更好的疗效估计。我们把这两个承诺**拆开**做样本外检验, 结论是: **前一条基本由方法的构造决定后一条这两个公开队列判不出来**; 而且**单靠队列人数、事件数或有效样本量, 定不出「多少数据才够」的通用门槛**。这是一篇否定性的方法学论文。

二、为什么值得重做一遍

三点。第一, 已有的评价都是**样本内的**——在同一批病人身上选标准、又在同一批病人身上打分, 这是乐观偏倚的经典场景。第二, 「更多病人」和「更好估计」被当成一对结果一起报告, 但没有理由认为两者需要同样多的数据, 甚至它们根本不是同一类命题。第三, 风险比**不可折叠**: 只要缩小人群, 即使每一层里的条件效应完全没变, 风险比也会移动。

三、怎么做的

样本外 按治疗组和事件分层随机对半分, 只在一半上跑规则选标准, 把选出的方案拿到**另一半**上打分, 重复 500 (colon) 和 400 (Rotterdam) 次。

全子集对照 规则保留的是标准的一个子集, 所以「比完整方案纳入更多人」不可能有别的结果。我们把全部 512 个子集都在留出那一半上打分, 在**相同入组人数**下比较, 并看规则离可达前沿有多远。

嵌套重抽 重复划分用的是同一批病人, 跨划分的标准误低估总体不确定性。外层按**病人 ID** 对队列自助抽样 (避免同一病人的副本落到划分两侧), 尝试把划分噪声和病人抽样变异近似分开——对有些量, 后者在我们能负担的蒙特卡洛精度下并不可辨识。

模拟与因子设计 真值已知、评分集固定 10 万人, 只让拟合集大小变化; 再用分辨率 IV 部分因子设计在六个因子上各取两水平, 共 16 个情景, 报告固定样本量下的成功概率。

两个公开队列做基准: **colon** (辅助结肠癌随机试验, $n = 619$, 完整方案保留 176 人、56 事件) 和 **Rotterdam** (乳腺癌登记队列, $n = 2982$, 保留 419 人、191 事件)。事件数比人数小得多, 也更要紧。

四、五个发现

1. 「多纳入病人」主要是构造性的

规则保留的是完整方案标准的子集, 所以合格人数只增不减——500 次划分里最小差值恰好是 0, 从不为负。文献常报的那个「承诺兑现率」衡量的是规则**移除了起约束作用的标准**的频率, 而不是移除对不对。真正要问的是: 在**同样多的人**下, 它的疗效估计是否更好。

2. 相同入组人数下的优势: 这两个队列判不出来

在合格人数相差 10% 以内的子集中, 规则的风险比更低的比例是 63.4% (colon) 和 57.1% (Rotterdam); 换成 RMST 差是 41.1% 和 59.0%, 两个队列**方向相反**。重抽病人时, 中间 80% 的范围是 [0.37–0.69] 和 [0.45–0.71], 宽度分别是 0.32 和 0.26。我们把它当作**统计量对队列构成有多敏感**来报告, 不当作检验; 文中没有做过任何有校准的总体层面比较。

3. 规则很少落在前沿上, 但那个前沿本身是乐观的

若存在另一个子集, 纳入人数不少于规则、风险比不高于规则, 就说规则被支配。规则落在前沿上的比例只有 3.0% 和 1.0%, 平均有 117 和 85 个子集支配它。但这个前沿是在**同一批留出数据**上从 512 个带噪声的估计里挑最优挑出来的, 带「胜者诅咒」式的乐观偏倚: 真值已知的模拟里, 表面支配者只有 19.5% 在总体上真的支配, 37.6% 能在另一半独立数据上重现。在真实队列里我们用**三分法**把这件事做干净: 第一份拟合规则, 第二份挑出支配它的子集, **这些子集固定之后**再拿到从未用过的第三份上重新评价。规则不被任何预选子集支配的比例是 21.0% (colon) 和 12.0% (Rotterdam), 而同一设计下挑选份上的经验口径只有 2.5% 和 2.7%。预选支配者在未用过那份上仍然支配的比例是 35.3% 和 41.4%。方向不变——大多数划分里规则仍被支配——但只报挑选份上的数会把差距夸大一个量级。

4. 疗效估计这条承诺: 既不能说守住, 也不能说没守住

样本外风险比更低的比例, colon 是 0.290、Rotterdam 是 0.522。重抽病人时它们的中间 80% 范围是 [0.04–0.60] 和 [0.20–0.80], 跨过大半个单位区间。所以这两个数是**这两份数据集的性质**, 不是对方法成功率的估计; 用它们下「承诺没守住」的判断是过头的。相比之下入组承诺稳得多 ([0.92–1.00]), 因为它是构造性的。

5. 「多少数据才够」没有通用答案

在已知真值的模拟里门槛是清楚的: 拟合集从 300 人到 20000 人, 疗效承诺的成功率从 0.273 升到 0.997。但换一个机制, 这条曲线就换一个位置。跨 16 个情景, 同一固定样本量下成功率的标准差在 0.28 到 0.39 之间; 改用事件数或有效样本量分箱也没有把这个离散度压下去 (0.34、0.35、0.34)。这三个数只是**在这一种分箱方式下数值相近**, 不能证明三种「信息货币」等价。混杂会把门槛推高: 同一个结局模型下, 随机化那一臂在 5167 人处成功率是 0.937, 正确调整的混杂臂只有 0.808;

而漏掉一个混杂因子反而把表观可靠性拉回随机化水平（0.936），同时把估计量的总体极限抬高 8.6%、把选对标准的比例从 0.280 压到 0.116。也就是说，表面上更可靠恰恰是偏倚的症状。

核心数字一览

量（方括号内为重抽病人的中间 80% 范围）	colon	Rotterdam
全队列：n / 完整方案保留人数 / 事件	619 / 176 / 56	2982 / 419 / 191
评分半样本上：完整方案 → 规则的合格人数（均值）	88 → 149	210 → 435
P(比完整方案纳入更多)	98.8% [0.92–1.00]	100.0% [1.00–1.00]
P(样本外风险比更低)	29.0% [0.04–0.60]	52.3% [0.20–0.80]
相同人数下风险比更低（10% 带）	63.4% [0.37–0.69]	57.1% [0.45–0.71]
相同人数下 RMST 更好（10% 带）	41.1% [0.31–0.57]	59.0% [0.43–0.71]
落在人数—风险比前沿上	3.0% [0.00–0.08]	1.0% [0.00–0.12]
三分法：不被任何预选子集支配	21.0% [0.04–0.28]	12.0% [0.08–0.28]
三分法：同一设计挑选份上的经验口径	2.5%	2.7%
三分法：预选支配者在未用份上重现	35.3% [0.31–0.50]	41.4% [0.29–0.50]

点估计来自 500（colon）／400（Rotterdam）次重复划分，三分法为 400／300 次。方括号是外层按病人 ID 自助抽样后中间 80% 的范围，不是置信区间：覆盖率未经验证，全文没有结论建立在它是否跨过某个值之上。Rotterdam 涉及风险比的结果只作描述。

五、文章明确不主张什么

这一节很重要，因为这篇稿子的价值有一半在边界上。我们不说 Trial Pathfinder 是错的——总体层面上我们复现的规则确实收敛到最优标准集。我们不说疗效承诺没守住，只说这两个队列判不出来。我们不说「无条件的数据量要求不存在」，只说在所考察的机制里、单靠队列规模定不出来，而且我们也说不出决定它的是哪个量。我们不把病人重抽范围当作置信区间：它们的覆盖率没有对着已知总体验证过，流程里还有 Shapley 取符号和前沿挑选两个非光滑步骤，所以全文没有任何结论建立在「范围是否跨过 0.5 或 0」之上；等效性方面只说明未预设等效界值、也未做等效性检验。Rotterdam 的重叠很差（完整方案的 419 人里有 132 人的倾向值压在截断边界上，加权后有效样本量只剩 37%），所以它所有涉及风险比的结果都只作描述。

六、三个能被单独拿走用的副产品

交互杠杆 闭式量 $L = 1 - p(ij)/p(i) - p(ij)/p(j) + p(ij)$ ，只入组率、不碰结局数据，动手前就能算。AND／OR／XOR 三种形式的系数分别是 $(1-q)^2$ 、 $-(1-q)^2$ 、 $-2(1-q)^2$ 。杠杆低不等于「结构上测不出」，而是按已知因子的衰减。

蕴含检测器 若标准 i 逻辑上蕴含 j，这对的交互是算术恒等式，无论样本量多大都无信息，必须从检验族里剔除。

双估计量并行 同时报风险比和 RMST 差。条件风险比固定为 0.6 的模拟里，一条没有改变任何人相对获益的标准，其对数风险比 Shapley 值却随预后异质性从 -0.0008 移到 -0.066（大体随异质性增大，但不严格单调）；异质性为零时假象消失。这就是不可折叠性在这套流程里的具体表现。

七、给要动手做的人的四步

- （1）先把出于安全性、耐受性、给药可行性的标准标记为**不可放宽**，它们不进入优化。
- （2）看结局之前先算交互杠杆和逻辑蕴含，把注定无信息的格子去掉。
- （3）检查完整方案内部的正性／重叠——重叠不好的话，后面所有因果读法都不成立。
- （4）判断方案里有没有一条标准集中了足够的差异获益；没有的话，就只报告人群扩大，**不报告疗效改善**。

八、局限

两个队列都不大，事件数分别只有 56 和 191，所以「判不出来」在相当程度上是**这两份数据的局限**，不是对方法的判决——这一点我们反复写明。标准是从可得协变量构造的，不是任何试验的方案原文，所以这研究的是**流程的一般行为**，不是对某个试验入组标准的评价。模拟只覆盖我们能想到的机制，因子设计只有 16 个固定设计点。