

这项工作做了什么

五张图 · 数据驱动放宽临床试验入组标准的一次样本外复查

Trial Pathfinder (Liu 等, Nature 2021) 用 Shapley 值挑出「限制了人数、却没给疗效估计带来好处」的入组标准并放宽, 宣称由此**同时**得到更多病人和更好的疗效估计。我们把这两个承诺**拆开**做样本外检验。结论是否定性的: **前一条基本由方法的构造决定, 后一条这两个公开队列判不出来**; 而且**单靠队列人数、事件数或有效样本量, 定不出「多少数据才够」的通用门槛**。

一、怎么做的

已有的评价都是**样本内的**——在同一批病人身上选标准、又在同一批病人身上打分, 这是乐观偏倚的经典场景。我们把选和评分分开:




图 1 研究设计。按治疗组和事件分层随机对半, 只在拟合半样本上跑规则, 把选出的方案拿到留出半样本上打分, 与完整方案对比。重复划分用的是同一批病人, 跨划分的标准低估总体不确定性, 所以外层再按**病人 ID** (而不是按行) 对整个队列自助重抽, 尝试把划分噪声和病人抽样变异近似分开——对有些量, 后者在我们能负担的蒙特卡洛精度下并不可辨识。两个公开队列: colon (辅助结肠癌随机试验, $n = 619$, 完整方案保留 176 人 / 56 事件) 与 Rotterdam (乳腺癌登记队列, $n = 2982$, 保留 419 人 / 191 事件)。事件数比人数小得多, 也更要紧。

二、「多纳入病人」是构造性的, 真正该问的是同样人数下谁更好

规则保留的是完整方案标准的一个子集, 合格人数只增不减——500 次划分里最小差值恰好是 0, 从不为负。所以「比完整方案纳入更多」不可能有别的结果。公平的对照是把全部 512 个子集都在留出的那一半上评分, 在**相同入组人数**下比较, 并看规则离可达前沿有多远:




图 2 一次划分里的全部 512 个子集 (colon, 500 次划分中的第一次, 未经挑选)。横轴是留出半样本上的合格人数, 纵轴是对数风险比, 越低越好。规则 (红星) 比完整方案 (蓝方块) 多纳入了病人, 但对数风险比反而更高; 绿色区域里有 44 个子集**两个维度都不比它差、且至少一个维度更好** (即支配它)。这一次划分的 44 个略低于 500 次划分的平均 117 个。整体上规则落在可达前沿上的比例只有 3.0% (colon) 和 1.0% (Rotterdam)。

三、相同人数下的优势: 这两个队列判不出来

在合格人数相差 10% 以内的子集中, 规则的风险比更低的比例是 63.4% (colon) 和 57.1% (Rotterdam); 换成 RMST 差是 41.1% 和 59.0%, **两个队列方向相反**。关键在于这些点估计有多远:




图 3 重抽病人时各个量的移动幅度。粗线是中间 80% 的范围，细线是 2.5-97.5% 的尾段，圆点是点估计。入组承诺（第一行）很稳，因为它是构造性的其余各行的范围都宽到占去单位区间的四分之一到大半，即对队列里恰好是哪些病人相当敏感。**这些不是置信区间：**外层每次重抽只做 25 次内层划分（点估计用 500 次），压缩校正只匹配二阶矩、不保证还原分位数，覆盖率也没有对着已知总体验证过。所以全文没有任何结论建立在「范围是否跨过 0.5」之上，也没有做过任何有校准的总体层面比较——我们只用它说明**统计量移动了多少**。

四、经验前沿本身是乐观的

图 2 里的前沿是在**同一批留出数据**上从 512 个带噪声的估计里挑最优挑出来的，带「胜者诅咒」式的乐观偏倚。真值已知的模拟给出量级：表面支配者只有 19.5% 在总体上真的支配，37.6% 能在另一半独立数据上重现。在真实队列里我们用三分法把挑选和评价彻底分开：




图 4 三分法。(a) 第一份拟合规则，第二份挑出支配它的子集，**这些子集固定之后再拿到从未用过的第三份上重新评价。**(b) 在挑选那一份上，规则不被支配的比例只有 2.5% 和 2.7%；换成未用过的那一份，是 21.0% 和 12.0%。方向不变——大多数划分里规则仍被支配——但只报挑选那一份的数会把差距夸大近一个量级。预选支配者在未用过那份上仍然支配的比例是 35.3% 和 41.4%。

五、「多少数据才够」没有通用答案

疗效承诺要多少数据才守得住？在真值已知的单一机制里，这个门槛是清楚的；换一个机制，曲线就换一个位置：




图 5 拟合集大小与成功概率。蓝线是单一机制下的曲线，从 300 人的 0.273 升到 20000 人的 0.997。橙色竖条是分辨率 IV 部分因子设计的 16 个情景在同一固定拟合规模下的跨度（依次位于 600、2000、6000、18 000 人），横杠是中位数。同一个样本量下，不同机制的成功概率可以从接近 0 到接近 1。跨情景的标准差在 0.28 到 0.39 之间；改用事件数或有效样本量分箱也没有把这个离散度压下去（0.34、0.35、0.34）——这三个数只是在**这一种分箱方式下数值相近**，不能证明三种「信息货币」等价。

混杂会把门槛推高，而且方向反直觉：同一个结局模型下，随机化那一臂在 5167 人处成功率是 0.937，正确调整的混杂臂只有 0.808；而**漏掉一个混杂因子**反而把表观可靠性拉回随机化水平（0.936），同时把估计量的总体极限抬高 8.6%、把选对标准的比例从 0.280 压到 0.116。**表面上更可靠恰恰是偏倚的症状。**

六、明确不主张什么

这篇稿子的价值有一半在边界上。我们**不说** Trial Pathfinder 是错的——总体层面上我们复现的规则确实收敛到最优标准集。我们**不说**疗效承诺没守住，只说这两个队列判不出来。我们**不说**「无条件的数据量要求不存在」，只说在所考察的机制里、单靠队列规模定不出来，而且我们也说不出决定它的是哪个量。我们**不把**病人重抽范围当作置信区间。Rotterdam 的重叠很差（完整方案的 419 人里有 132 人的倾向值压在截断边界上，加权后有效样本量只剩 37%），所以它所有涉及风险比的结果都只作描述。两个队列都不大，事件数分别只有 56 和 191，「判不出来」在相当程度上是**这两份数据的局限**，不是对方法的判决。

七、给要动手做的人的四步

（1）先把出于安全性、耐受性、给药可行性的标准标记为**不可放宽**，它们不进入优化。（2）看结局之前先算**交互杠杆**（闭式量 $L = 1 - p(ij)/p(i) - p(ij)/p(j) + p(ij)$ ，只用入组率、不碰结局数据）和**逻辑蕴含**，把注定无信息的格子去掉。（3）检查完整方案内部的正性／重叠——重叠不好的话，后面所有因果读法都不成立。（4）判断方案里有没有一条标准集中了足够的差异获益；没有的话，就只报告人群扩大，**不报告疗效改善**。

八、核心数字一览

量（方括号内为重抽病人的中间 80% 范围）	colon	Rotterdam
全队列 n / 完整方案保留人数 / 事件	619 / 176 / 56	2982 / 419 / 191
评分半样本：完整方案 → 规则的合格人数	88 → 149	210 → 435
P(比完整方案纳入更多)	98.8% [0.92–1.00]	100.0% [1.00–1.00]
P(样本外风险比更低)	29.0% [0.04–0.60]	52.3% [0.20–0.80]
相同人数下风险比更低（10% 带）	63.4% [0.37–0.69]	57.1% [0.45–0.71]
相同人数下 RMST 更好（10% 带）	41.1% [0.31–0.57]	59.0% [0.43–0.71]
落在人数—风险比前沿上	3.0% [0.00–0.08]	1.0% [0.00–0.12]
三分法：不被任何预选子集支配	21.0% [0.04–0.28]	12.0% [0.08–0.28]
三分法：同一设计挑选份上的经验口径	2.5%	2.7%
三分法：预选支配者在未用份上重现	35.3% [0.31–0.50]	41.4% [0.29–0.50]
RMST 规则与发表规则选出同一标准集	7.0%	20.8%

点估计来自 500／400 次重复划分（三分法 400／300 次）；方括号是外层按病人 ID 自助重抽 150 次后中间 80% 的范围，**不是置信区间**。全部数字由 analysis/out/numbers.json 一处导出，本文档生成时直接读取。